

大模型 AI Agent 算法岗位线上实习项目大纲：基于多模态大模型的桌面 GUI 智能体开发与优化

项目概述

- 项目名称：基于多模态大模型的桌面 GUI 智能体开发与优化
- 项目时长：8 周（2 个月）
- 项目目标：智能体赛道的核心技术方向，实现能够 "看懂屏幕、操作电脑" 的桌面 GUI 智能体原型，掌握多模态感知、任务规划、工具调用、模型微调等核心算法能力

项目背景

国内大模型与智能体技术的领军企业在通用智能体、多模态交互、数字员工、办公自动化等领域有深度布局。行业正在大力研发能够理解并操作图形界面的 GUI 智能体，应用于办公自动化 RPA、智能客服、无障碍交互、软件测试等核心业务场景。

当前主流的 GUI 智能体技术路线（如 Ui-TARS、Claude Computer Use、OpenAI Operator）均基于 "多模态视觉理解 + 大模型任务规划 + 桌面控制执行" 的架构。本项目聚焦桌面端 GUI 智能体的端到端实现与优化这一核心问题。

项目周计划与交付物明细

周数	核心工作模块	细分执行任务	数据 / 工具来源	阶段交付物
第 1 周	行业技术调研与开发环境搭建	1. 研读技术博客中关于智能体、多模态大模型的最新文章2. 深入研究 Ui-TARS、Claude Computer Use、ScreenAgent 的技术论文与开源实现3. 分析 GUI 智能体的核心技术架构与关键挑战4. 搭建完整的 Python 开发环境，配置 CUDA 加速（如有 GPU），测试基础工具库	1. 技术博客、火山引擎开发者社区2. arXiv 论文预印本平台、GitHub 开源仓库3. Python 官方、PyTorch 官方文档	《GUI 智能体技术调研报告》+ 开发环境配置文档
	桌面感知	1. 实现跨平台屏幕实时截图功能，支持多分辨率	1. PyAutoGUI、PyQt5 开	桌面感知与控制模

第2周	与控制核心模块开发	适配2. 集成开源 OCR 工具，实现屏幕文字与 UI 元素识别3. 开发鼠标键盘控制模块，支持点击、输入、滚动、拖拽等基本操作4. 实现 UI 元素坐标定位与边界框绘制功能	源库2. PaddleOCR、EasyOCR 开源 OCR 工具 3. OpenCV 计算机视觉库	块完整代码 + 单元测试报告
第3周	公开 GUI 数据集处理与基础 Agent 框架搭建	1. 下载并预处理 ScreenAgent、WebArena、Mind2Web 等公开 GUI 任务数据集2. 基于 LangChain/ LlamaIndex 搭建基础多模态 Agent 框架3. 实现简单的任务拆解与规划能力4. 开发大模型调用接口，支持开源多模态模型的本地部署与 API 调用	1. Hugging Face Datasets、GitHub 开源数据集仓库2. LangChain、LlamaIndex 开源 Agent 框架3. Qwen-VL、GLM-4V、Llama 3.2 Vision 开源多模态模型	数据集预处理脚本 + 基础 Agent 框架代码
第4周	端到端 GUI 任务执行系统集成	1. 将感知模块、控制模块与 Agent 框架进行无缝集成2. 实现 "用户指令→屏幕感知→任务规划→动作执行→结果反馈" 的完整闭环3. 开发简单的命令行交互界面4. 测试并调试 5 个基础桌面任务：打开浏览器、搜索指定内容、打开指定文件、发送消息、关闭应用	1. 前序开发的所有模块代码2. 本地测试环境与测试用例	端到端 GUI 智能体系统原型 v1.0 + 基础任务测试报告
第5周	多模态大模型 LoRA 微调与能力提升	1. 基于预处理后的公开 GUI 数据集，构建微调训练集与验证集2. 使用 PEFT 库实现对开源多模态模型的 LoRA 微调3. 对比微调前后模型在 GUI 任务理解与动作生成上的效果4. 优化提示词工程，提升模型的任务执行准确率	1. Hugging Face Transformers、PEFT、Accelerate 库2. 前序处理的公开数据集3. 本地 GPU 或 Google Colab GPU 资源	微调后的模型权重 + 微调效果对比分析报告
第6周	高级功能与系统鲁棒性优化	1. 实现复杂任务的自动拆解与分步执行能力2. 开发错误检测与自动重试机制，提升系统容错性3. 优化屏幕感知模块，提升 UI 元素识别的准确率与速度4. 实现任务执行状态的实时监控与日志记录	1. 前序开发的系统代码2. OpenCV、PaddleOCR 优化文档3. Python logging 日志库	优化后的系统 v2.0 + 鲁棒性测试报告

第 7 周	系统全面评估与性能分析	1. 设计包含 20 个不同难度桌面任务的测试集2. 从任务成功率、平均执行时间、错误率等维度进行定量评估3. 分析系统在不同应用、不同分辨率下的表现差异4. 对比本项目实现与 Ui-TARS、Claude Computer Use 的技术差距	1. 自行设计的测试任务集 2. Excel/Google Sheets 数据统计工具3. Matplotlib 数据可视化库	《系统全面评估报告》+ 性能分析可视化图表
第 8 周	项目总结与求职作品集整合	1. 撰写完整的技术报告，详细阐述技术架构、实现细节、实验结果与创新点2. 制作系统演示视频，展示核心功能与效果3. 整理项目代码，添加详细注释与使用说明	1. 前序所有交付物2. 剪映 / 必剪视频剪辑工具3. Markdown 编辑器、LaTeX 编辑器	完整项目代码仓库 + 深度技术报告 + 系统演示视频

项目技术栈

1. 基础开发环境

- 编程语言：Python 3.10+
- 深度学习框架：PyTorch 2.2+
- 硬件支持：本地 NVIDIA GPU（推荐 8GB 以上显存）或 Google Colab GPU 资源
- 版本控制：Git + GitHub

2. 桌面感知与控制模块

- 屏幕截图：PyAutoGUI、mss（高性能截图）
- UI 元素识别：OpenCV、PaddleOCR、EasyOCR
- 鼠标键盘控制：PyAutoGUI、pynput
- 跨平台支持：支持 Windows、macOS、Linux

3. 大模型与 Agent 框架

- 开源多模态大模型：Qwen-VL-Chat、GLM-4V-9B、Llama 3.2 Vision 11B
- Agent 框架：LangChain、LlamaIndex
- 模型部署：Transformers、vLLM（加速推理）
- 提示词工程：LangChain Prompt Templates

4. 模型微调工具

- 参数高效微调：PEFT（LoRA 实现）
- 训练加速：Accelerate、bitsandbytes（4/8 位量化）
- 数据集处理：Datasets、Pandas

5. 可视化与演示工具

- 数据可视化：Matplotlib、Seaborn
- 演示视频：剪映 / 必剪
- 文档编写：Markdown、Typora

参考资料与官方链接

核心技术论文

- UI-TARS: Pioneering Automated GUI Interaction with Native Agents: <https://arxiv.org/abs/2501.12326>
- Claude Computer Use 官方技术文档: <https://claudecn.com/docs/source-analysis/computer-use/>
- ScreenAgent: A Multimodal Agent for Screen Understanding and Control: <https://github.com/niuzaisheng/ScreenAgent>
- WebArena: A Realistic Web Environment for Building Autonomous Agents: <https://arxiv.org/abs/2307.13854>

开源工具与数据集

- LangChain 官方文档: <https://python.langchain.com/>
- Hugging Face Transformers: <https://huggingface.co/docs/transformers/index>
- Qwen-VL 开源模型: <https://huggingface.co/Qwen/Qwen-VL-Chat>
- ScreenAgent 数据集: <https://github.com/niuzaisheng/ScreenAgent>
- WebArena 数据集: <https://github.com/web-arena-x/webarena>

学习资源

- 吴恩达《多模态大模型与智能体》课程：https://www.bilibili.com/video/BV1MqVz6tEk9/?vd_source=e37291f1d47d4a36381eb691230c9042
- 李沐《动手学深度学习》：<https://zh.d2l.ai/>

合规与落地说明

1. 本项目所有代码与模型均基于开源协议使用，严格遵守各开源项目的许可条款。
2. 项目仅用于学习与研究目的，严禁用于任何非法用途或未经授权的系统操作。
3. 所有数据集均来自公开开源渠道，严禁用于商业用途。
4. 如无本地 GPU 资源，可完全使用 Google Colab GPU 资源完成模型微调与推理。
5. 项目中涉及的所有操作均在本地计算机上进行，不包含任何个人数据或敏感信息。